

STAGE DE FIN D'ÉTUDE

Blue Ranging

Auteur :
Zhengyang GU

Responsables :
M. Eric LECONTE
M. Gilles CHARDON

DRAFT

7 novembre 2017

Table des matières

1	Introduction	4
1.1	Valeo	4
1.2	InBlue	4
1.2.1	Contexte	4
1.2.2	Principe de fonctionnement et bénéfices	5
1.3	Blue Ranging	5
1.4	Contenus du stage	6
2	Calcul de la distance	7
2.1	Modèle des observations	7
2.2	Méthode de phase	8
2.2.1	Deux fréquences ranging	8
2.2.2	Multi-fréquences ranging	9
2.3	Méthode conventionnelle	11
2.3.1	Transformée de Fourier inverse	11
2.3.2	Transformée de Fourier inverse avec une fenêtre	11
2.3.3	Résultats	11
2.4	Méthode de haute résolution	13
2.4.1	Matrice de covariance	13
2.4.2	Décorrélacion de la matrice de covariance	13
2.4.3	Estimation du nombre des composantes	15
2.4.4	MUSIC (Multiple Signal Classification) et Root-MUSIC	16
2.4.5	Min-Norm	18
2.4.6	ESPRIT (Estimation of Signal Parameters via Rotational Invariance Techniques)	18
2.4.7	Résultats	19
2.5	Méthode de haute résolution linéaire	22
2.5.1	OPM (Orthonormal Propagator Method) et Root-OPM	22
2.5.2	SWEDE (Subspace method Without Eigen DEcomposition)	23
2.5.3	ESPRITWED (ESPRIT Without Eigen Decomposition)	24
2.5.4	Résultats	24
2.6	Méthode de parcimonie	24
2.6.1	Formalisation du problème LASSO	24
2.6.2	FISTA (Fast Iterative Shrinkage Thresholding Algorithm)	27
2.6.3	Résultats	27
2.6.4	Amélioration du calcul	29
2.7	Comparaisons de résolution	29

2.7.1	Comparaison des résultats sans bruit	29
2.7.2	Comparaison des résultats avec le bruit	31
2.8	Bilan de comparaison	31
3	Prédiction de la zone	34
3.1	Introduction	34
3.1.1	RKE (Remote Keyless Entry)	34
3.1.2	PEPS (Passive Entry Passive Start)	34
3.1.3	PEPS avec le smartphone	34
3.2	Méthode	34
3.2.1	Architecture du système	34
3.2.2	Cahier des charges : PEPS zones	34
3.2.3	RSSI (Received Signal Strength Indication) et atténuation	36
3.2.4	Choix des attributs	37
3.2.5	Random Forest	39
3.3	Résultat	39
4	Conclusion	41

Table des figures

1	Processus de construire le vecteur des observations	8
2	Régression linéaire sur la phase pour un chemin	10
3	Régression linéaire sur la phase pour deux chemins	10
4	Réponse Fréquentielle des fenêtres	12
5	Résultat de la méthode conventionnelle : IFFT	12
6	Fonctions discriminantes et fonction de coût pour $K = 3$	17
7	Résultat de la méthode haute résolution : MUSIC	20
8	Résultat de la méthode haute résolution : Root-MUSIC	20
9	Résultat de la méthode haute résolution : Min-Norm	21
10	Résultat de la méthode haute résolution : ESPRIT	21
11	Résultat de la méthode haute résolution linéaire : OPM	25
12	Résultat de la méthode haute résolution linéaire : Root-OPM	25
13	Résultat de la méthode haute résolution linéaire : SWEDE	26
14	Résultat de la méthode haute résolution linéaire : ESPRITWED	26
15	Résultat de la méthode de parcimonie : FISTA	28
16	Résultat de la méthode de parcimonie : FISTA pour la bande WIFI	28
17	Approche adaptative	30
18	Résultat de la méthode de parcimonie : FISTA avec une grille adaptative	30
19	Comparaison des performances sans bruit	31
20	Comparaison des performances avec le bruit : SNR = 10dB	32
21	Position des beacons sur la voiture	35
22	Cahier des charges : PEPS zones	35
23	Atténuation théorique du signal reçu par le smartphone	37
24	Atténuation de propagation dans le canal réel	38
25	Atténuation par le corps	38
26	Influence de la polarisation du smartphone	39
27	Matrice de confusion sur le modèle de Random Forest	40

Liste des tableaux

1	Bilan de comparaison	33
---	--------------------------------	----

1 Introduction

1.1 Valeo

Valeo est un acteur majeur de la filière automobile mondiale et compte parmi les premiers équipementiers mondiaux. Entreprise technologique, le groupe est entièrement focalisé sur la conception, la fabrication et la vente de composants, de modules et de systèmes intégrés pour l'industrie automobile et poids lourds en première monte. Il est aussi présent sur le marché de l'après-vente.

Valeo, avec son concept de « conduite intuitive », se concentre sur le développement de technologies innovantes qui assurent une sécurité optimale, un confort de conduite amélioré et une efficacité énergétique accrue. Le groupe propose des solutions pour réduire la consommation des moteurs à combustion interne et celle des véhicules hybrides et électriques, et des solutions pour diminuer la consommation d'énergie et le poids des composants.

Valeo est organisé en 4 pôles et une activité deuxième monte, Valeo Service. Le pôle systèmes de propulsion développe des solutions de propulsion innovantes visant à réduire la consommation de carburant et les émissions de CO₂. Le pôle systèmes thermiques développe et fabrique des systèmes, des modules et des composants assurant la gestion de l'énergie thermique du groupe motopropulseur ainsi que le confort de chaque passager dans l'habitacle. Le pôle systèmes de confort et d'aide à la conduite développe des systèmes d'interface entre le conducteur, le véhicule et son environnement, contribuant à l'amélioration du confort et de la sécurité. Le pôle systèmes de visibilité conçoit et produit des systèmes innovants qui assurent au conducteur une parfaite visibilité, contribuant ainsi à sa sécurité et à celle de ses passagers. Valeo service fournit des pièces de rechange aux constructeurs automobile et au marché de la rechange indépendante. Il propose à tous les réseaux de la rechange dans le monde une large gamme de produits et services.

1.2 InBlue

Valeo étend les capacités de ses systèmes d'accès mains-libres pour intégrer les nouveaux usages et comportements liés à l'internet des objets tels que les smartphones, les smartwatches et lance en première mondiale un système de montre connectée pour verrouiller, déverrouiller sa voiture. Une fois dans la voiture, le smartphone du conducteur est détecté et lui permet de démarrer. A partir de son smartphone, le système InBlue permet également l'auto-partage, le parking à distance et l'accès aux données du véhicule telles que la pression des pneus, le niveau de carburant, ou la localisation de son véhicule. Avec cette innovation, Valeo démontre son savoir faire d'intégrateur de compétences. La démonstration InBlue a été développée en collaboration avec Safran-Morpho, l'un des leaders mondiaux en matière de sécurité électronique, et Vulog un expert reconnu des solutions d'auto-partage. Il fait partie du projet européen "DEWI" (Dependable Embedded Wireless Infrastructure).

1.2.1 Contexte

L'utilisation de smartphones connaît une augmentation fulgurante. En 2013, 900 millions de smartphones ont été vendus dans le monde (source Gartner). Le nombre de montres connectées devraient atteindre 37 millions en 2015 d'après le cabinet NextMarket Insights. Parallèlement, selon les estimations de Valeo, 27% des véhicules en Europe sont équipés de systèmes d'accès mains-libres et cette part devrait s'élever à 40% d'ici 2020. Enfin, les comportements d'usage évoluent. Selon l'étude de L'Observatoire Cetelem 2014, plus de quatre européens sur dix se

disent prêts à partager l'usage d'un véhicule d'ici dix ans. Pour accompagner ces tendances, Valeo a développé InBlue, un système d'accès et de démarrage compatible avec les smartphones et les montres connectées.

1.2.2 Principe de fonctionnement et bénéfices

- **Une nouvelle génération de système d'accès et de démarrage mains libres**

InBlue, est une nouvelle génération de système d'accès et de démarrage mains libres utilisant la technologie Bluetooth Smart. Elle s'intègre facilement au véhicule. La communication avec le smartphone est assurée par une clé virtuelle stockée dans le téléphone grâce à la plate-forme sécurisée InBlue, offrant un niveau de confiance équivalent aux processus de paiement sur mobile.

- **L'automobiliste toujours plus connecté à son véhicule**

Avec InBlue, le conducteur peut non seulement utiliser son véhicule sans sortir la clé de sa poche, mais il peut également laisser ses clés à son domicile. Il utilisera tout simplement son smartphone et sa montre connectée pour déverrouiller, verrouiller et démarrer sa voiture. Les fonctionnalités du système sont très étendues : InBlue permet de synchroniser les informations entre la voiture et le smartphone. Le conducteur peut ainsi à tout moment et à distance prendre connaissance d'une multitude d'informations concernant son véhicule, telles que la pression des pneus, le niveau de carburant, la distance de la prochaine station essence sans oublier la localisation de son véhicule. Ces informations sont régulièrement enregistrées sur le smartphone et sont donc disponibles à tout moment et quelque soit la distance entre le véhicule et le conducteur.

- **InBlue permet de transmettre sa clé virtuellement à un tiers et facilite l'auto-partage**

Prêter sa voiture ou demander à une tierce personne de récupérer le véhicule à l'autre bout de la ville, demande de l'anticipation et toute une organisation. Plus besoin de trouver une cachette pour la clé ou de penser à remettre le double des clés. Avec InBlue le conducteur peut « transmettre » sa clé de voiture à distance et à tout moment, quel que soit l'endroit où il se trouve. Il lui suffit d'envoyer une clé numérique à la personne qui empruntera son véhicule via le smartphone. Le récipiendaire est alors habilité à utiliser son smartphone pour déverrouiller, verrouiller et démarrer la voiture. Le conducteur peut ainsi attribuer de façon permanente ou temporaire une clé à toutes les personnes susceptibles d'utiliser sa voiture. Une avancée de taille, notamment pour les concessionnaires, sociétés de location de véhicules ou gestionnaires de flottes qui pourront bénéficier des avantages du système InBlue pour simplifier certains processus, comme la gestion des clés des véhicules de leur parc.

- **La connectivité pour intégrer d'autres systèmes**

Enfin, ce nouveau système d'accès mains-libres est compatible avec les systèmes de parking à distance Park4U Remote et Valet Park4U grâce à la technologie Bluetooth Smart.

1.3 Blue Ranging

Afin de sécuriser et d'améliorer le système InBlue, une fonctionnalité de localisation du smartphone est nécessaire. Cette localisation permettra :

- d'autoriser le démarrage du véhicule seulement si le propriétaire du véhicule se trouve à l'intérieure de celui-ci

- d'autoriser le déverrouillage des portes du véhicule seulement si le propriétaire se trouve proche du véhicule (par exemple à 2 mètres)
- de ne pas verrouiller les portes du véhicule en laissant le smartphone à l'intérieure du véhicule
- de proposer un accueil lorsque l'utilisateur s'approche de son véhicule (allumage des feux de croisement du véhicule par exemple)
- de faire une sélection de l'ouverture en fonction de la trajectoire d'approche (ouverture du coffre, seulement de la porte conducteur, etc.)

Cette solution de localisation est appelée Blue Ranging par Valeo. La localisation du smartphone est faite soit par calculer la distance précise entre le smartphone et la voiture, soit par déterminer la zone où se trouve le smartphone.

1.4 Contenus du stage

Le stage est principalement focalisé sur la localisation du smartphone par rapport à la voiture. Dans un premier temps, je cherchais des algorithmes pour calculer la distance précise entre le smartphone et la voiture en comparant les performances (la précision, la résolution et le coût calculatoire). Il fait appel aux méthodes de traitement d'antennes. La comparaison des algorithmes est faite sous la simulation Matlab. Dans un deuxième temps, j'essayais de déterminer la zone où se trouve le smartphone au lieu de calculer une distance précise. On définit cinq zones pour la localisation du smartphone : zone intérieur, zone de déverrouillage gauche, zone de déverrouillage droite, zone de déverrouillage coffre et zone de verrouillage. Il est validé en utilisant des vraies données et il fait appel aux méthodes de Machine Learning.

2 Calcul de la distance

L'estimation de retard (distance) fait appel aux méthodes d'analyse spectrale. Ces méthodes ont été adaptées par le passé aux différents domaines du traitement du signal : estimation de direction d'arrivée (DDA) à partir d'un réseau d'antennes, estimation de fréquences pures dans un signal (analyse spectrale), estimation de retards de propagation à partir d'un signal temporel ou fréquentiel. Les deux premiers domaines ont suscité le plus grand nombre de développements. Ce chapitre est focalisée sur l'estimation de retards de propagation à partir d'un signal fréquentiel. On distingue schématiquement cinq grandes familles de méthodes : méthode de phase, méthode conventionnelle, méthode de haute résolution, méthode de haute résolution linéaire et méthode de parcimonie.

2.1 Modèle des observations

Les principales techniques de traitement du signal présentées dans ce chapitre font appel à un modèle de signal a priori. Dans notre modèle, l'émetteur envoie successivement des signaux de différentes fréquences dans une bande et le signal reçu par le récepteur est la somme de tous les échos. Chaque écho est lié avec un trajet et le trajet est dénoté par un retard de phase et une atténuation (coefficient de réflexion).

Dans le domaine fréquentiel, le modèle des observations est une combinaison linéaire d'exponentielles complexes, dont les arguments dépendent des paramètres à estimer :

$$\tilde{s}(f) = \sum_{i=1}^K c_i \tilde{e}(f) e^{-2j\pi f T_i} + \tilde{b}(f), \quad f \in B \quad (1)$$

où le symbole $\tilde{\cdot}$ représente la transformée de Fourier du signal temporel. Le vecteur des observations fréquentiel contenant les N échantillons de mesures fréquentielles dans une bande B est noté \mathbf{s} . Il représente indifféremment le résultat de la transformée de Fourier d'un signal obtenu par un signal impulsionnel ou des mesures obtenues par un signal à saut de fréquence. Il peut s'écrire sous la forme matricielle suivante :

$$\mathbf{s} = \mathbf{A}\mathbf{c} + \mathbf{b} \quad (2)$$

avec les notations suivantes :

- $\mathbf{s} = (\tilde{s}(f_1) \quad \tilde{s}(f_2) \quad \cdots \quad \tilde{s}(f_N))^T$: Vecteur de mesure ou des observations de dimension $(N, 1)$
- $\mathbf{c} = (c_1 \quad c_2 \quad \cdots \quad c_K)^T$: Vecteur d'amplitudes complexes des échos ou vecteur des coefficients de réflexion de dimension $(K, 1)$
- $\mathbf{A} = (\mathbf{a}(T_1) \quad \mathbf{a}(T_2) \quad \cdots \quad \mathbf{a}(T_K))$: Matrice mode ou matrice des vecteurs modèles de dimension (N, K) , dont les colonnes représentent les vecteurs modèles à identifier
- $\mathbf{a}(T_i) = (e^{-2j\pi f_1 T_i} \quad e^{-2j\pi f_2 T_i} \quad \cdots \quad e^{-2j\pi f_N T_i})^T$: Vecteur directionnel de dimension $(N, 1)$ comportant le paramètre T_i à déterminer
- $\mathbf{b} = (\tilde{b}(f_1) \quad \tilde{b}(f_2) \quad \cdots \quad \tilde{b}(f_N))^T$: Vecteur du bruit de dimension $(N, 1)$
- $\mathbf{f} = (f_1 \quad f_2 \quad \cdots \quad f_N)^T$: Vecteur de fréquence avec une bande $B = [f_1 \quad f_N]$




FIGURE 1 – Processus de construire le vecteur des observations

En pratique, le vecteur des observations \mathbf{s} est construit de la manière suivante :

- L'émetteur envoie successivement des pures signaux avec différentes fréquences (f_1, f_2, \dots, f_N)
- Mesurer l'amplitude et la phase pour chaque fréquence sur le récepteur

Le processus est démontré par la figure 1.

2.2 Méthode de phase

La méthode de phase est un moyen efficace pour l'estimation de la distance dans le cas où il y a seulement un trajet de transmission (pas de réflexion). On peut utiliser deux ou plusieurs fréquences pour le calcul de la distance.

2.2.1 Deux fréquences ranging

Supposons que l'émetteur envoie deux signaux de fréquences f_1 et f_2 , on calcule la distance de propagation à partir de deux phases mesurées sur le récepteur :

$$\phi_i = \phi_0 - 2\pi f_i T = \phi_0 - 2\pi f_i \frac{D}{c}, \quad i = 1, 2 \quad (3)$$

alors,

$$D = -\frac{c}{2\pi} \frac{\Delta\phi}{\Delta f} \quad (4)$$

avec les notations suivantes :

- ϕ_0 la phase initiale émise par l'émetteur

- $\Delta\phi = \phi_2 - \phi_1$ la différence de phase reçue par le récepteur
- $\Delta f = f_2 - f_1$ la différence de fréquence
- c la vitesse de propagation et D la distance

Étant donné que la différence de phase $\Delta\phi$ est toujours inférieure à 2π , la distance maximale envisagée est

$$D_{max} = \frac{c}{\Delta f} \quad (5)$$

Cette dernière est aussi appelée la distance d'ambiguïté. Par exemple, si l'on utilise une bande de 80MHz, on a une distance d'ambiguïté de 3.75m. Cela signifie que toutes les distances de 1m, 4.75m, 8.5m, \dots ont le même résultat.

2.2.2 Multi-fréquences ranging

La performance de la méthode précédente pourrait être dégradée dans certaines situations. La limitation principale est le compromis entre la distance maximale d'ambiguïté et la sensibilité au bruit[1]. Un grand écart de fréquences pourrait réduire la sensibilité au bruit mais avoir une petite distance d'ambiguïté, cela pourrait être insuffisante pour certaines applications. Par ailleurs, certaines fréquences pourraient être totalement atténuées, cela nous donne une phase peu fiable. Une variante est d'utiliser plusieurs fréquences, cela nous donne un résultat plus robuste.

De même façon, on a

$$\phi_i = \phi_0 - 2\pi f_i T = \phi_0 - 2\pi f_i \frac{D}{c}, \quad i = 1, 2, \dots, N \quad (6)$$

alors,

$$D = -\frac{c}{2\pi} \frac{\delta\phi}{\delta f} \quad (7)$$

où $\frac{\delta\phi}{\delta f}$ est la pente de la régression linéaire entre la phase ϕ et la fréquence f . La pente peut être calculée de la manière suivante :

$$\phi = \mathbf{X}\beta + \mathbf{n} \Rightarrow \hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \phi \quad (8)$$

avec les notations ci-dessous :

- $\phi = (\phi_1 \quad \phi_2 \quad \dots \quad \phi_N)^T$: Vecteur de phase
- $\mathbf{X} = [\mathbf{1} \quad \mathbf{f}]$: Matrice des données
- β : Vecteur des coefficients de régression dont la deuxième est la pente

Sous Matlab, on a simulé d'abord une distance de 1.5m avec un SNR 10dB (Signal Noise Ratio). On utilise la bande de Bluetooth 2400MHz-2480MHz pour le calcul de la distance. On peut déduire la distance à partir de la pente montrée par la figure 2 : on obtient une distance 1.47m.

Dans un deuxième temps, on a simulé deux chemins de 1m et 4m sans bruit. La figure 3 montre qu'il y a un changement brutal de pente. En utilisant la même méthode, on obtient le résultat 5.14m, ce qui est un résultat erroné même sans bruit.




FIGURE 2 – Régression linéaire sur la phase pour un chemin




FIGURE 3 – Régression linéaire sur la phase pour deux chemins

2.3 Méthode conventionnelle

Le méthode de phase peut échouer dans le cas où il y a plusieurs trajets de transmission (plusieurs réflexions). Les prochaines parties de ce rapport sont dédiées à résoudre ce problème de multipath ou au moins à trouver le chemin le plus court. Une méthode conventionnelle est la méthode de transformée de Fourier inverse (IFFT).

2.3.1 Transformée de Fourier inverse

Les échantillons fréquentiels du signal obéissent au modèle des observations défini par l'équation 1. Ils correspondent, soit à la transformée de Fourier du signal temporel, soit directement aux mesures délivrées par un signal à sauts de fréquence.

La transformée de Fourier inverse est définie par l'intégrale suivante, qui permet d'estimer le signal temporel $s(t)$ à partir du signal fréquentiel associé $\tilde{s}(f)$:

$$s(t) = \int_{\mathbb{R}} \tilde{s}(f) e^{2i\pi ft} df \quad (9)$$

En général, la valeur des retards de propagation est déduite de la position des maxima du signal $s(t)$.

2.3.2 Transformée de Fourier inverse avec une fenêtre

Étant donné que le signal fréquentiel est disponible que dans la bande du Bluetooth (2.4GHz), il s'agit d'ajouter une fenêtre rectangulaire dans l'équation 9 :

$$\hat{s}(t) = \int_{\mathbb{R}} \tilde{s}(f) w(f) e^{2i\pi ft} df$$

où

$$w(f) = \begin{cases} 1, & f \in B \\ 0, & \text{else} \end{cases} \quad (10)$$

La réponse fréquentielle d'une fenêtre rectangulaire a un grand lobe secondaire, cela peut conduire à estimer une valeur de distance erroné si un second trajet s'ajoute à ce lobe. Une amélioration est d'utiliser une fenêtre d'apodisation telle que la fenêtre de hanning avant d'effectuer la transformée de Fourier inverse.

La figure 4 montre que la réponse fréquentielle d'une fenêtre de Hanning a un lobe secondaire plus petit que celui de Rectangle. Cela peut réduire le nombre des pics du signal $s(t)$. Par contre, la réponse fréquentielle de Hanning a une largeur de lobe principal plus grande que celle de Rectangle, cela réduit la résolution temporelle. D'après la simulation, on a constaté une résolution de 3.75m pour l'IFFT normal et une résolution d'environ 5m pour l'IFFT avec une fenêtre de Hanning.

2.3.3 Résultats

On a simulé deux chemins sous Matlab avec la première distance 2m et la deuxième 6m. On a ajouté aussi des bruits avec un SNR de 10dB. La figure 5 montre que la méthode IFFT arrive à distinguer ces deux chemins mais avec un erreur de 50cm. L'avantage de cette méthode est qu'elle calcule le résultat très vite (0.004s).

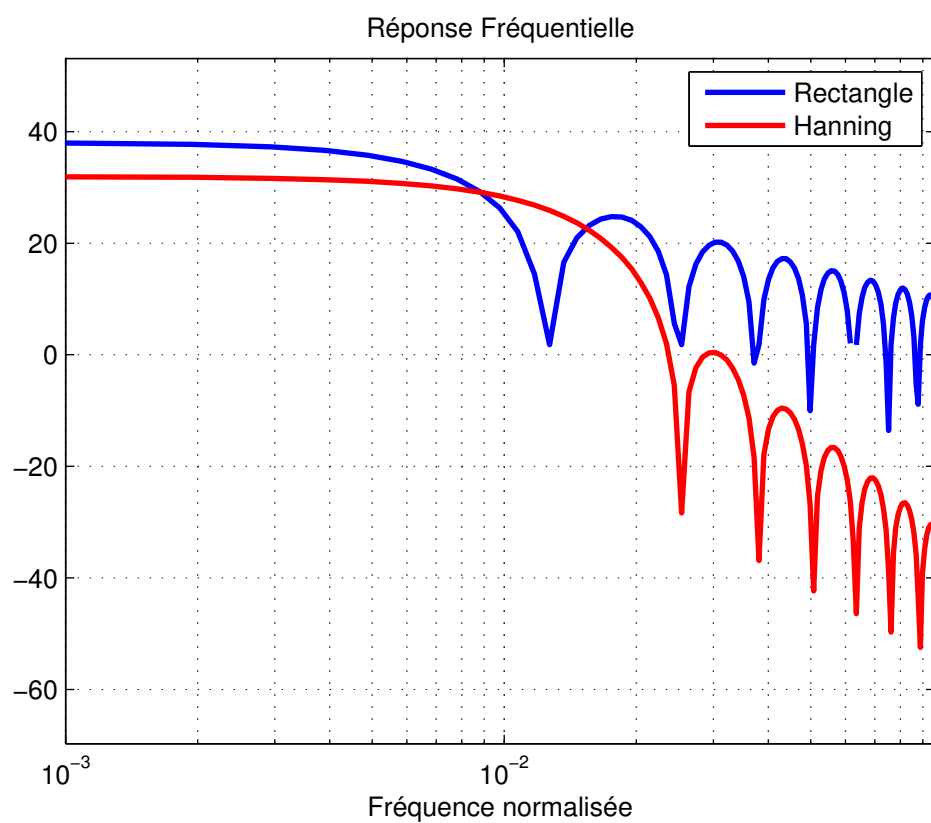


FIGURE 4 – Réponse Fréquentielle des fenêtres




FIGURE 5 – Résultat de la méthode conventionnelle : IFFT

2.4 Méthode de haute résolution

Les méthodes à haute résolution ou HR apparaissent dans les années 1970 dans les domaines de l'acoustique sous-marine, de la sismique et de la radioastronomie. Par comparaison avec les méthodes conventionnelles, les méthodes HR présentent la caractéristique de fournir en terme de résolution, des performances asymptotiquement illimitées et indépendantes du rapport signal sur bruit. Cette famille d'algorithmes (MUSIC, Root-MUSIC, Min-Norm, ESPRIT) a été principalement appliquée au domaine du traitement d'antennes, dont l'objectif est d'estimer des directions d'arrivée, à partir du signal enregistré sur un réseau d'antennes. Cette partie présente le principe de ces méthodes à sous-espace, à partir de la formation du modèle du signal fréquentiel.

2.4.1 Matrice de covariance

Les méthodes HR exposées dans cette section peuvent se formuler à partir de la matrice de covariance. La matrice d'auto-corrélation du vecteur des observations \mathbf{s} , associée au modèle du signal dans le domaine fréquentiel décrit par l'équation 1, est définie par :

$$\mathbf{\Gamma} = E(\mathbf{s}\mathbf{s}^H) \quad (11)$$

où $\mathbf{\Gamma}$ est une matrice de dimension (N, N) et l'opérateur $E(\cdot)$ représente l'espérance mathématique. La matrice d'auto-corrélation est égale à la matrice de covariance des observations \mathbf{s} si $E(\mathbf{s}) = 0$. En utilisant le modèle du signal décrit par l'équation 2, la matrice de covariance s'écrit selon :

$$\mathbf{\Gamma} = \mathbf{A}\mathbf{\Gamma}_c\mathbf{A}^H + \sigma^2\mathbf{\Sigma} \quad (12)$$

avec $\mathbf{\Gamma}_c$ et $\sigma^2\mathbf{\Sigma}$, les matrices de covariance des sources et du bruit respectivement. La matrice de covariance du bruit est définie par :

$$\sigma^2\mathbf{\Sigma} = E(\mathbf{b}\mathbf{b}^H) \quad (13)$$

Pour un bruit blanc, elle se réduit à la matrice identité \mathbf{I} de dimension N . L'expression de la matrice de covariance $\mathbf{\Gamma}$ s'écrit :

$$\mathbf{\Gamma} = \mathbf{A}\mathbf{\Gamma}_c\mathbf{A}^H + \sigma^2\mathbf{I}_N \quad (14)$$

En pratique, la matrice de covariance est estimée à partir de la moyenne des N_{obs} matrices élémentaires $\hat{\mathbf{\Gamma}}_i$, obtenues à partir de mesures indépendantes sur une même bande. L'estimation de la matrice de covariance des observations s'écrit alors sous la forme :

$$\hat{\mathbf{\Gamma}} = \frac{1}{N_{obs}} \sum_{i=1}^{N_{obs}} \hat{\mathbf{\Gamma}}_i = \frac{1}{N_{obs}} \sum_{i=1}^{N_{obs}} \mathbf{s}_i\mathbf{s}_i^H \quad (15)$$

2.4.2 Décorrélacion de la matrice de covariance

Dans le cas où les signaux sont décorrés, la procédure décrite par l'équation 15 permet d'obtenir une estimation de matrice de covariance des observations. En revanche, lorsque les signaux sont totalement corrélés, cette procédure n'est pas suffisante pour utiliser les méthodes à sous-espace [2]. C'est le cas pour l'application du Blue Ranging où tous les trajets sont corrélés l'un avec l'autre. Pour résoudre ce problème, des méthodes de moyennage en sous-bandes sont utilisées. Ainsi, ces méthodes de moyennage en sous-bandes permettent d'estimer une matrice de covariance rectifiée des observations. Ces techniques de moyennage ont pour but de diminuer artificiellement la corrélation entre échos et permettent de favoriser le fonctionnement des algorithmes. Parmi les techniques, nous pouvons citer le moyennage direct (SSP : Spatial Smoothing

Processing) et le moyennage direct-inverse (MSSP : Modified Spatial Smoothing Processing) [3].

Ces méthodes, telles que le moyennage direct (SSP) et le moyennage direct-inverse (MSSP) font appel à un découpage de la bande totale de fréquences en M sous-bandes $B^{(m)}$, $m = 1, 2, \dots, M$. Chaque sous-bande est associée avec une matrice de covariance $\mathbf{\Gamma}^{(m)}$ selon la procédure décrite par l'équation 15. avec :

- L : Largeur de chaque sous-bande
- M : Nombre des sous-bandes
- N : Nombre total d'échantillons du signal reçu
- $B^{(m)} = [f_m \quad f_{m+L-1}]$: m ième sous-bande
- $\mathbf{\Gamma}^{(m)}$: Matrice de covariance pour la sous-bande $B^{(m)}$

En général, la relation entre L , M et N s'écrit sous la forme :

$$N = L + M - 1 \quad (16)$$

Dans ce cas, on a une bande de fréquence effective de largeur :

$$B_{eff} = f_L - f_1 \quad (17)$$

La matrice de covariance rectifiée des observations avec la méthode de moyennage direct, $\mathbf{\Gamma}_{ssp}$, s'exprime comme la moyenne des matrices de covariance des sous-bandes des observations $\mathbf{\Gamma}^{(m)}$ telle que :

$$\mathbf{\Gamma}_{ssp} = \frac{1}{M} \sum_{m=1}^M \mathbf{\Gamma}^{(m)} \quad (18)$$

La matrice de covariance rectifiée des observations avec la méthode de moyennage direct-inverse, $\mathbf{\Gamma}_{mssp}$, s'exprime comme la moyenne des matrices de covariance des sous-bandes des observations dans le sens direct et dans le sens rétrograde. Cette matrice de covariance rectifiée s'exprime alors sous la forme :

$$\mathbf{\Gamma}_{mssp} = \frac{1}{2M} \sum_{m=1}^M (\mathbf{\Gamma}^{(m)} + \mathbf{J}(\mathbf{\Gamma}^{(m)})^* \mathbf{J}) \quad (19)$$

avec \mathbf{J} la matrice de permutation, qui permet de générer le vecteur des données dans le sens rétrograde :

$$\mathbf{J} = \begin{bmatrix} 0 & 0 & \dots & 1 \\ 0 & \dots & \dots & 0 \\ \vdots & 1 & \dots & \vdots \\ 1 & 0 & \dots & 0 \end{bmatrix} \quad (20)$$

D'après la thèse [3], il est important de faire un compromis entre les paramètres des méthodes de moyennage en sous-bande : le nombre de sous-bandes M ou bien la largeur de la bande effective L . Pour la méthode de moyennage direct (SSP), la largeur de la bande effective doit être comprise entre 50 et 70% de la bande totale. En revanche, pour la méthode de moyennage direct-inverse (MSSP), la largeur de la bande effective doit être comprise entre 70 et 90% de la bande totale. En effet, la méthode de moyennage direct-inverse permet d'obtenir d'une part une meilleure résolution et d'autre part une meilleure robustesse par rapport au bruit.

Les méthodes de moyennage en sous-bande peuvent être performantes en terme de décorrélation de la matrice de covariance. Par contre, ils utilisent une sous-bande avec une largeur plus petite par rapport à la bande totale. Du fait que la résolution temporelle est inversement proportionnelle à la largeur de la bande [3], cela signifie qu'on perde la résolution temporelle en utilisant ces méthodes de moyennage en sous-bande. Une autre méthode de décorrélation de matrice de covariance est la méthode de Toeplitz [4].

Il existe deux variantes de l'algorithme de Toeplitz classique qui fait un moyennage sur les amplitudes ou sur les phases des éléments situés dans la diagonale de la matrice de covariance. [4] propose une version optimale de la méthode de Toeplitz : il choisit des éléments dans la première ligne et la première colonne pour construire une matrice Toeplitz :

$$\begin{aligned} \mathbf{\Gamma} &= \begin{bmatrix} r_{11} & r_{12} & \cdot & r_{1(N-1)} & r_{1N} \\ r_{21} & r_{22} & \cdot & r_{2(N-1)} & r_{2N} \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ r_{(N-1)1} & r_{(N-1)2} & \cdot & r_{(N-1)(N-1)} & r_{(N-1)N} \\ r_{N1} & r_{N2} & \cdot & r_{N(N-1)} & r_{NN} \end{bmatrix} \\ \Rightarrow \mathbf{\Gamma}_{\text{Toep}} &= \begin{bmatrix} r_{11} & r_{12} & \cdot & r_{1(N-1)} & r_{1N} \\ r_{21} & r_{11} & \cdot & \cdot & r_{1(N-1)} \\ \cdot & \cdot & \cdot & \cdot & \cdot \\ r_{(N-1)1} & \cdot & \cdot & r_{11} & r_{12} \\ r_{N1} & r_{(N-1)1} & \cdot & r_{21} & r_{11} \end{bmatrix} \end{aligned} \quad (21)$$

Contrairement aux méthodes en sous-bande qui réalisent la décorrélation des signaux en diminuant la bande effective, la méthode de Toeplitz réalise la décorrélation par le changement de la structure des données de la matrice de covariance et toute la bande est employée. Cela signifie que la méthode de Toeplitz nous donne une meilleure résolution temporelle que les méthodes en sous-bande. Par contre, on a constaté que les méthodes en sous-bande sont plus performantes et robustes que celles de Toeplitz en terme de l'estimation du nombre des composantes. Donc, il faut faire un compromis entre la résolution temporelle et l'estimation du nombre des signaux.

2.4.3 Estimation du nombre des composantes

Les méthodes de haute résolution nécessitent de décomposer l'espace des observations en deux espaces orthogonaux, soit un espace signal et un espace bruit. Cette décomposition est basée sur les valeurs propres de la matrice de covariance. Akaike information critère (AIC) [5] est une méthode classique pour estimer la dimension de l'espace signal dans le cas du bruit Gaussien. Le nombre des composantes est déterminé pour avoir une meilleure concordance entre le modèle et les observations. Le critère est écrite sous la forme :

$$K = \arg \min_k C(k) \quad (22)$$

où $C(k)$ est une fonction de coût associée avec le nombre des composantes pour $K = k$.

Par contre, Rissanen a démontré que l'estimation de AIC n'est pas consistante et a proposé un nouveau critère de minimum description length (MDL) [6] pour résoudre ce problème. Ci-dessous est décrit les fonctions de coût pour AIC et MDL respectivement :

$$AIC(k) = -2P(N - k) \log \left\{ \frac{\prod_{i=k+1}^N \lambda_i^{1/(N-k)}}{(1/(N - k)) \sum_{i=k+1}^N \lambda_i} \right\} + 2k(2N - k)$$

$$MDL(k) = -P(N - k) \log \left\{ \frac{\prod_{i=k+1}^N \lambda_i^{1/(N-k)}}{(1/(N-k)) \sum_{i=k+1}^N \lambda_i} \right\} + \frac{1}{2}k(2N - k) \log P \quad (23)$$

avec N , taille du vecteur et P , nombre de réalisation.

L'estimation de MDL est consistante, mais elle pourrait être sous-estimée dans le cas où il y a moins de réalisations. [7] propose un nouveau critère pour estimer la dimension de l'espace signal. Cette proposition utilise deux fonctions discriminantes $g_1(k)$ et $g_2(k)$:

$$C_{new}(k) = g_1(k) - g_2(k) \quad (24)$$

Les valeurs propres sont rangées par ordre décroissant. La fonction $g_1(k)$ est choisie comme la variation des dernières $N - 1$ valeurs propres :

$$g_1(k) = \frac{\lambda_{k+1}}{\sum_{i=2}^N \lambda_i}, \quad k = 1, \dots, N - 1 \quad (25)$$

La fonction $g_2(k)$ est choisie pour avoir une variation inverse selon la fonction $g_1(k)$:

$$g_2(k) = \frac{\xi_k}{\sum_{i=1}^{N-1} \xi_i}, \quad k = 1, \dots, N - 1 \quad (26)$$

avec

- $\xi_k = 1 - \alpha(\lambda_k - \mu_k)/\mu_k$
- $\mu_k = 1/(N - k) \sum_{i=k+1}^N \lambda_i$
- $\alpha \max[(\lambda_k - \mu_k)/\mu_k] = 1$

$C_{new}(k)$ est décroissante et l'estimation des composantes associée avec ce nouveau critère, l'équation 24 est déduite par le paramètre maximale k qui nous donne une valeur positive de la fonction de coût $C_{new}(k)$:

$$K = \arg \min_k C_{new}(k) \quad s.t. \quad C_{new}(k) > 0 \quad (27)$$

La figure 6 montre un exemple pour le nombre des composantes $K = 3$.

2.4.4 MUSIC (MUltiple SIgnal Classification) et Root-MUSIC

La méthode MUSIC a été initialement proposée par Schmidt et Bienvenu et Kopp dans le domaine du traitement d'antennes au cours des années 1980. L'algorithme MUSIC exploite les propriétés de décomposition en éléments propres de la matrice de covariance du vecteur des observations en deux sous-espaces orthogonaux : le sous-espace signal et le sous-espace bruit. La matrice de covariance est de dimension (N, N) , elle se décompose dans une base de N vecteurs propres orthogonaux. La distribution d'amplitude des valeurs propres permet de faire la distinction entre l'espace signal et l'espace bruit. On distingue $N - K$ valeurs propres égales à la variation du bruit σ^2 et K valeurs propres supérieures à σ^2 . La dimension du signal K est déduite en utilisant les méthodes décrites dans la section 2.4.3. On peut construire un espace signal \mathbf{E}_s à partir des vecteurs propres associées avec K premières valeurs propres et un espace bruit \mathbf{E}_b à partir des vecteurs propres associées avec les restes $N - K$ valeurs propres :

$$\mathbf{E}_s = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_K]$$

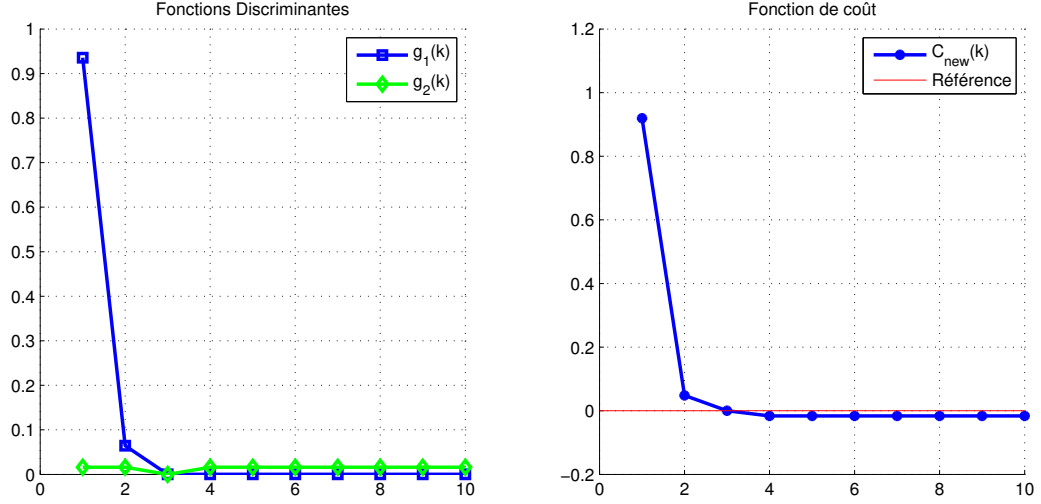


FIGURE 6 – Fonctions discriminantes et fonction de coût pour $K = 3$

$$\mathbf{E}_b = [\mathbf{v}_{K+1}, \mathbf{v}_{K+2}, \dots, \mathbf{v}_N] \quad (28)$$

où $\mathbf{v}_i, i = 1, 2, \dots, N$ sont des vecteurs propres associés avec les valeurs propres $\lambda_i, i = 1, 2, \dots, N$ par ordre décroissant.

Sachant que le vecteur directionnel $\mathbf{a}(T_i)$, défini par l'équation 1, appartient au sous-espace signal, on peut définir un pseudo-spectre $P(t)$ qui mesure l'orthogonalité entre le vecteur directionnel $\mathbf{a}(T_i)$ et l'espace bruit \mathbf{E}_b . Ce pseudo-spectre obtient un maximum quand le vecteur directionnel est perpendiculaire au sous-espace bruit.

$$P(t) = \frac{1}{\|\langle \mathbf{a}(t), \mathbf{E}_b \rangle\|_2^2} = \frac{1}{\mathbf{a}^H(t) \mathbf{E}_b \mathbf{E}_b^H \mathbf{a}(t)} \quad (29)$$

En pratique, la valeur des retards de propagation est déduite de la position des maxima de ce pseudo-spectre $P(t)$. L'amplitude des maxima n'a aucune signification physique, mais mesure uniquement l'orthogonalité entre les deux sous-espace.

La méthode MUSIC calcule un pseudo-spectre pour tous les temps d'échantillonnage t . Donc, la précision de cette méthode dépend du pas d'échantillonnage temporel. Cela signifie que une meilleure précision demande un coût calculatoire plus important. Root-MUSIC désigne la version polynomiale de l'algorithme MUSIC. Cette méthode polynomiale permet d'estimer directement les retards de propagation sans nécessiter le calcul du pseudo-spectre. En introduisant $z = e^{-2j\pi\Delta f t}$, on peut définir un nouveau vecteur directionnel $\mathbf{a}(z) = (1 \ z^{-1} \ \dots \ z^{N-1})^T$. Donc, la recherche des maxima sur le pseudo-spectre, l'équation 29, devient à trouver des racines d'un polynôme $P(z)$:

$$P(z) = \mathbf{a}(z^{-1})^T \mathbf{E}_b \mathbf{E}_b^H \mathbf{a}(z) \quad (30)$$

$P(z)$ est un polynôme de degré $N - 2$. Le caractère hermitien du projecteur $\mathbf{E}_b \mathbf{E}_b^H$ entraîne une symétrie des racines : Si z est une racine, alors $1/z^*$ est aussi une racine du polynôme $P(z)$. En pratique, les retards estimés sont donnés par les K racines se trouvant à la fois à l'intérieur du cercle unité et au plus proche de celui-ci.

L'intérêt de la version polynomiale est double : la recherche des racines d'un polynôme est beaucoup moins coûteuse que l'évaluation puis la recherche des maxima dans un pseudo-spectre et Root-MUSIC possède un pouvoir de résolution supérieure à MUSIC [8].

2.4.5 Min-Norm

Le processus de la méthode Min-Norm ressemble à celui de MUSIC sauf qu'il utilise un vecteur du sous-espace bruit \mathbf{w} pour définir un pseudo-spectre $P(t)$:

$$P(t) = \frac{1}{\| \langle \mathbf{a}(t), \mathbf{w} \rangle \|^2_2} = \frac{1}{\| \mathbf{a}(t)^H \mathbf{w} \|^2_2} \quad (31)$$

\mathbf{w} est calculé de la manière suivante :

- \mathbf{w} est un vecteur du sous-espace bruit, donc, il est orthogonal à l'espace signal \mathbf{E}_s :

$$\mathbf{E}_s^H \mathbf{w} = \mathbf{0} \quad (32)$$

- On écrit \mathbf{w} et \mathbf{E}_s^H sous les formes suivantes :

$$\mathbf{w} = \begin{bmatrix} 1 \\ -\tilde{\mathbf{w}} \end{bmatrix} \quad \mathbf{E}_s = [\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_K] = \begin{bmatrix} \mathbf{g}^T \\ \mathbf{G} \end{bmatrix} \quad (33)$$

- En utilisant la relation entre \mathbf{w} et \mathbf{E}_s^H , l'équation 32, on obtient :

$$\mathbf{g} - \mathbf{G}^H \tilde{\mathbf{w}} = \mathbf{0} \quad (34)$$

- Par conséquent, nous avons :

$$\tilde{\mathbf{w}} = \frac{\mathbf{G} \mathbf{g}^*}{1 - \mathbf{g}^H \mathbf{g}} \quad \mathbf{w} = \begin{bmatrix} 1 \\ -\frac{\mathbf{G} \mathbf{g}^*}{1 - \mathbf{g}^H \mathbf{g}} \end{bmatrix} \quad (35)$$

Enfin, la valeur des retards de propagation est déduite de la position des maxima du pseudo-spectre défini par l'équation 31. Cette méthode présente un meilleur pouvoir de résolution que MUSIC, mais elle est plus sensible à la qualité de la matrice de covariance [8].

2.4.6 ESPRIT (Estimation of Signal Parameters via Rotational Invariance Techniques)

Contrairement aux précédentes méthodes à sous-espace, la méthode ESPRIT permet une estimation directe des paramètres à partir du modèle des observations fréquentielles. Cet algorithme exploite la relation linéaire entre les données de deux sous-bandes de fréquences adjacentes. En partitionnant la matrice mode \mathbf{A} de la manière suivante :

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_1 \\ - \end{bmatrix} = \begin{bmatrix} - \\ \mathbf{A}_2 \end{bmatrix} \quad (36)$$

on obtient la relation suivante :

$$\mathbf{A}_2 = \mathbf{A}_1 \Phi \quad (37)$$

La matrice Φ peut être vue comme un opérateur de rotation. Elle est diagonale de dimension (K, K) , dont les éléments diagonaux sont fonctions des retards de propagation :

$$\Phi = \begin{bmatrix} e^{-2j\pi\Delta f T_1} & 0 & \cdot & 0 \\ 0 & e^{-2j\pi\Delta f T_2} & 0 & \cdot \\ \cdot & \cdot & \cdot & \cdot \\ \cdot & \cdot & \cdot & e^{-2j\pi\Delta f T_K} \end{bmatrix} \quad (38)$$

Supposons que la matrice diagonale Λ est constituée de toutes les valeurs propres de Γ :

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & 0 \\ 0 & \dots & 0 \\ 0 & 0 & \lambda_N \end{bmatrix} \quad (39)$$

En multipliant l'équation 14 par la matrice du signal \mathbf{E}_s , on obtient :

$$\Gamma \mathbf{E}_s = \mathbf{A} \Gamma_c \mathbf{A}^H \mathbf{E}_s + \sigma^2 \mathbf{E}_s = \mathbf{E}_s \Lambda \quad (40)$$

Donc, on a :

$$\mathbf{E}_s = \mathbf{A} (\Gamma_c \mathbf{A}^H \mathbf{E}_s \Lambda_0^{-1}) \triangleq \mathbf{A} \mathbf{T} \quad (41)$$

avec :

$$\Lambda_0 = \begin{bmatrix} \lambda_1 - \sigma^2 & 0 & 0 \\ 0 & \dots & 0 \\ 0 & 0 & \lambda_N - \sigma^2 \end{bmatrix} \quad (42)$$

En partitionnant la matrice du signal \mathbf{E}_s de même manière que la matrice mode \mathbf{A} :

$$\mathbf{E}_s = \begin{bmatrix} \mathbf{E}_{s1} \\ - \end{bmatrix} = \begin{bmatrix} - \\ \mathbf{E}_{s2} \end{bmatrix} \quad (43)$$

On obtient les relations :

$$\mathbf{E}_{s1} = \mathbf{A}_1 \mathbf{T}$$

$$\mathbf{E}_{s2} = \mathbf{A}_2 \mathbf{T} \quad (44)$$

On peut déduire la relation entre \mathbf{E}_{s1} et \mathbf{E}_{s2} :

$$\mathbf{E}_{s2} = \mathbf{A}_2 \mathbf{T} = \mathbf{A}_1 \Phi \mathbf{T} = \mathbf{E}_{s1} \mathbf{T}^{-1} \Phi \mathbf{T} \triangleq \mathbf{E}_{s1} \mathbf{F} \quad (45)$$

La matrice \mathbf{F} peut être calculée à partir de la matrice \mathbf{E}_{s1} et \mathbf{E}_{s2} . La solution au sens des moindres carrés est donnée par la relation suivante :

$$\hat{\mathbf{F}} = (\mathbf{E}_{s1}^H \mathbf{E}_{s1})^{-1} \mathbf{E}_{s1}^H \mathbf{E}_{s2} \quad (46)$$

Du fait que $\mathbf{F} = \mathbf{T}^{-1} \Phi \mathbf{T}$, la matrice \mathbf{F} et la matrice Φ engendrent les mêmes valeurs propres. Cela signifie qu'on peut estimer les retards de propagation à partir des valeurs propres de la matrice \mathbf{F} .

En comparaison des algorithmes nécessitant le calcul du pseudo-spectre, tels que MUSIC et Min-Norm, le coût de calcul de la méthode ESPRIT est réduit. [9] a montré que la méthode ESPRIT a une variance inférieure à celle de MUSIC.

2.4.7 Résultats

De même façon, on a simulé deux chemins (2m et 6m) avec un SNR 10dB. On compare les performances de ces méthodes : MUSIC, Min-Norm et ESPRIT. Les figures 7 8 9 et 10 donnent respectivement les résultats. On peut remarquer que tous ces méthodes nous permettent d'avoir une très bonne précision. En ce qui concerne le coût calculatoire, la méthode ESPRIT garde la meilleure performance.

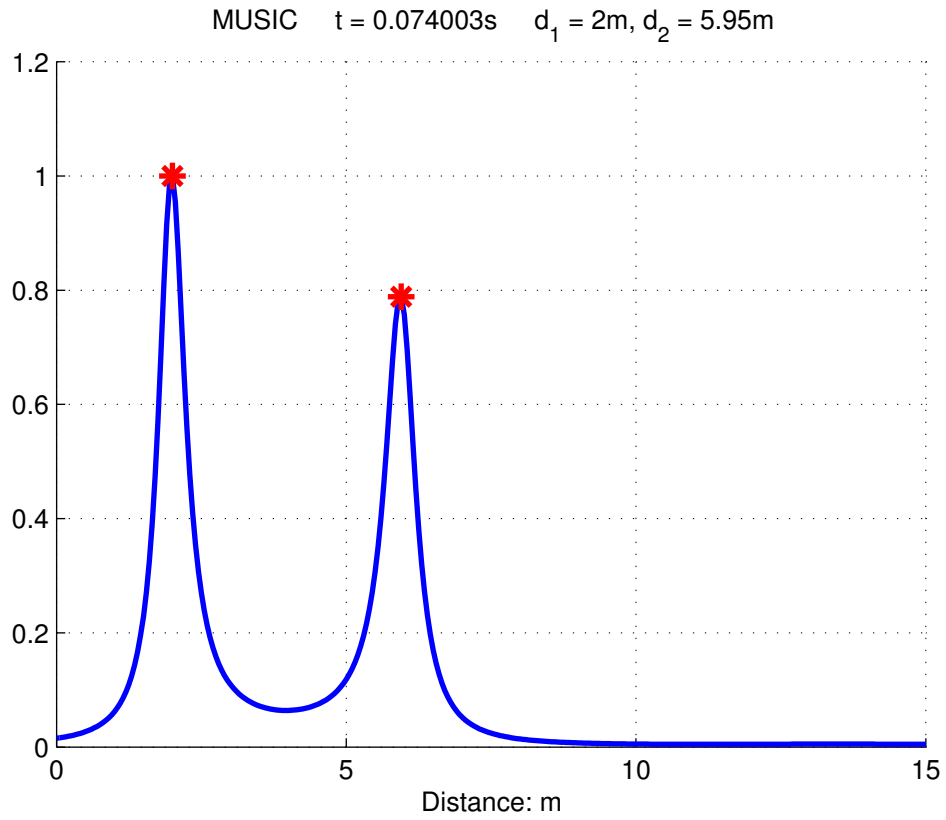


FIGURE 7 – Résultat de la méthode haute résolution : MUSIC

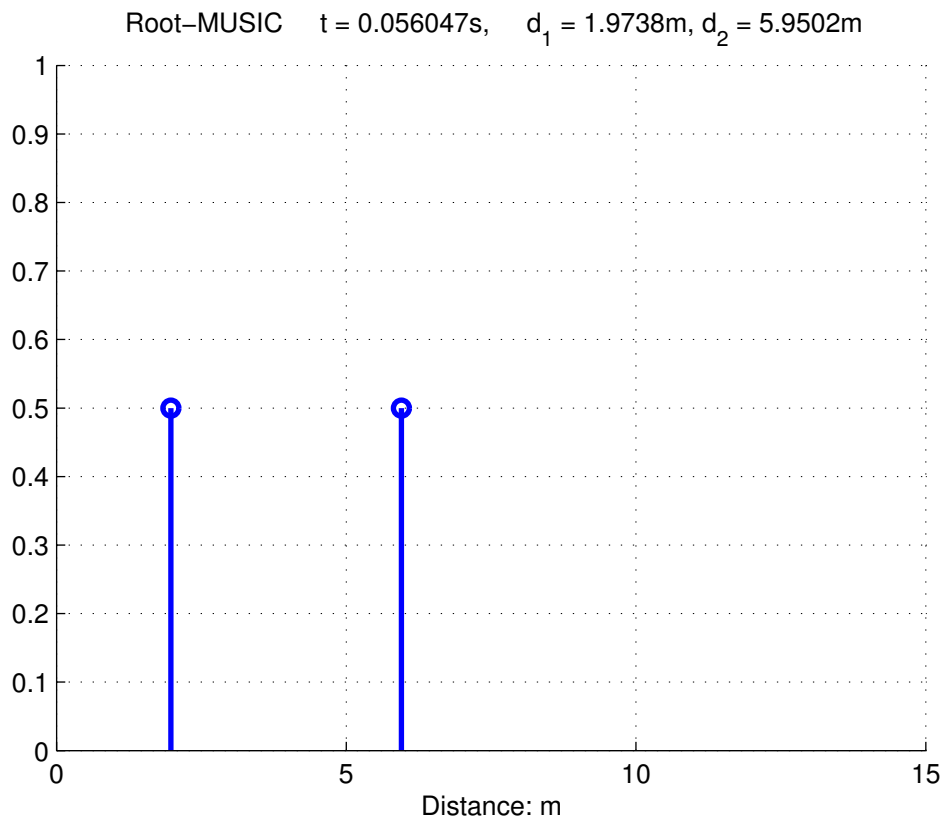


FIGURE 8 – Résultat de la méthode haute résolution : Root-MUSIC




FIGURE 9 – Résultat de la méthode haute résolution : Min-Norm




FIGURE 10 – Résultat de la méthode haute résolution : ESPRIT

2.5 Méthode de haute résolution linéaire

Les méthodes d'analyse spectrale Haute Résolution (HR) basées sur la décomposition en éléments propres de la matrice de covariance sont apparues dans les années 80. Dans le courant des années 90, sont apparues les méthodes HR linéaires telles que BEWE, OPM et SWEDE. Ces méthodes linéaires conservent la performance haute résolution mais avec un coût de calcul moins important : elles ne nécessitent plus de décomposition en élément propre de la matrice de covariance. En conséquence, elles sont potentiellement applicables en temps réel et mieux adaptées au traitement d'un grand volume de données. Cette partie présente les méthodes typiques telles que OPM, SWEDE et leurs extensions.

2.5.1 OPM (Orthonormal Propagator Method) et Root-OPM

Sous l'hypothèse que la matrice mode \mathbf{A} est de rang K , il existe K lignes de \mathbf{A} linéairement indépendantes. Le fonctionnement de l'algorithme OPM repose sur le partitionnement de la matrice mode :

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \end{bmatrix} \quad (47)$$

où \mathbf{A}_1 et \mathbf{A}_2 sont des matrices de dimension (K, K) et $(N - K, K)$ respectivement. La méthode OPM utilise la matrice de propagateur \mathbf{P} qui est de dimension $(K, N - K)$:

$$\mathbf{A}_2 = \mathbf{P}^H \mathbf{A}_1 \Leftrightarrow \begin{bmatrix} \mathbf{P}^H & -\mathbf{I}_{N-K} \end{bmatrix} \mathbf{A} = \mathbf{Q}^H \mathbf{A} = \mathbf{0} \quad (48)$$

avec

$$\mathbf{Q} = \begin{bmatrix} \mathbf{P}^H & -\mathbf{I}_{N-K} \end{bmatrix} \quad (49)$$

La matrice de propagateur \mathbf{P} peut être calculée à partir de la matrice de covariance $\mathbf{\Gamma}$ de la manière suivante :

- On partitionne la matrice de covariance $\mathbf{\Gamma}$ comme suit : $\mathbf{\Gamma} = \begin{bmatrix} \mathbf{\Gamma}_1 & \mathbf{\Gamma}_2 \end{bmatrix}$ où $\mathbf{\Gamma}_1$ et $\mathbf{\Gamma}_2$ sont deux matrices de dimension (N, K) et $(N, N - K)$ respectivement
- On peut montrer que le propagateur vérifie : $\mathbf{\Gamma}_2 = \mathbf{\Gamma}_1 \mathbf{P}$
- La solution du propagateur \mathbf{P} au sens de la norme de Frobenius devient : $\hat{\mathbf{P}} = (\mathbf{\Gamma}_1^H \mathbf{\Gamma}_1)^{-1} \mathbf{\Gamma}_1^H \mathbf{\Gamma}_2$

La matrice \mathbf{Q} est orthogonale au sous-espace engendré par la matrice mode \mathbf{A} , l'équation 48 . De même manière que le principe de la méthode MUSIC, l'équation 29 , on peut définir aussi un pseudo-spectre $P(t)$:

$$P(t) = \frac{1}{\| \langle \mathbf{a}(t), \mathbf{Q} \rangle \|_2^2} = \frac{1}{\mathbf{a}^H(t) \mathbf{Q} \mathbf{Q}^H \mathbf{a}(t)} \quad (50)$$

Contrairement à MUSIC, les colonnes de \mathbf{Q} ne définissent pas une base orthonormée. Il existe une autre version de pseudo-spectre qui utilise la matrice \mathbf{Q}_0 dont les colonnes sont orthonormées :

$$P(t) = \frac{1}{\| \langle \mathbf{a}(t), \mathbf{Q}_0 \rangle \|_2^2} = \frac{1}{\mathbf{a}^H(t) \mathbf{Q}_0 \mathbf{Q}_0^H \mathbf{a}(t)} \quad (51)$$

avec :

$$\mathbf{Q}_0 = \mathbf{Q} (\mathbf{Q}^H \mathbf{Q})^{-1/2} \quad (52)$$

La méthode OPM n'implique que des opérations linéaires sur des données, donc, elle a un coût de calcul moins important. Pour diminuer la complexité d'un facteur supplémentaire, il existe une version polynomiale appelée Root-OPM, inspirée de la méthode Root-MUSIC [3].

2.5.2 SWEDE (Subspace method Without Eigen DEcomposition)

Le fonctionnement de l'algorithme SWEDE repose sur le partitionnement de la matrice mode suivant :

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_1 \\ \mathbf{A}_2 \\ \mathbf{A}_3 \end{bmatrix} \quad (53)$$

où \mathbf{A}_1 , \mathbf{A}_2 et \mathbf{A}_3 sont des matrices de dimension (K, K) , (K, K) et $(N - 2K, K)$ respectivement. On peut définir ainsi une matrice \mathbf{W} de dimension $(N, 2(N - 2K))$:

$$\mathbf{W} = \begin{bmatrix} \mathbf{W}_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{W}_2 \\ \mathbf{I}_{N-2K} & \mathbf{I}_{N-2K} \end{bmatrix} \quad (54)$$

avec :

$$\begin{aligned} \mathbf{W}_1 &= -\mathbf{A}_1^{-H} \mathbf{A}_3^H \\ \mathbf{W}_2 &= -\mathbf{A}_2^{-H} \mathbf{A}_3^H \end{aligned} \quad (55)$$

On peut vérifier cette matrice \mathbf{W} est orthogonale à la matrice mode \mathbf{A} :

$$\mathbf{A}^H \mathbf{W} = \mathbf{0} \quad (56)$$

La matrice de covariance est partitionnée en matrice-blocs de dimensions correspondantes $(K, K, N - 2K)$:

$$\mathbf{\Gamma} = \begin{bmatrix} \mathbf{\Gamma}_{11} & \mathbf{\Gamma}_{12} & \mathbf{\Gamma}_{13} \\ \mathbf{\Gamma}_{21} & \mathbf{\Gamma}_{22} & \mathbf{\Gamma}_{23} \\ \mathbf{\Gamma}_{31} & \mathbf{\Gamma}_{32} & \mathbf{\Gamma}_{33} \end{bmatrix} \quad (57)$$

Les matrices \mathbf{W}_1 et \mathbf{W}_2 peuvent être estimées à partir des matrices-blocs :

$$\begin{aligned} \mathbf{W}_1 &= -\mathbf{\Gamma}_{21}^{-1} \mathbf{\Gamma}_{32}^H \\ \mathbf{W}_2 &= -\mathbf{\Gamma}_{12}^{-1} \mathbf{\Gamma}_{31}^H \end{aligned} \quad (58)$$

La méthode SWEDE utilise une matrice de rang plein \mathbf{V} telle que :

$$\mathbf{V} = \mathbf{W} \mathbf{D} \quad (59)$$

D'après l'équation 56 , cette matrice \mathbf{V} est orthogonale à la matrice mode \mathbf{A} . La matrice \mathbf{D} est de dimension $(2(N - 2K), p)$, où $1 \leq p \leq N - K$. [10] donne une version qui montre le meilleur compromis entre complexité et précision. Pour cette version, $p = N - K$ et \mathbf{D} est définie suivante :

$$\mathbf{D} = \begin{bmatrix} \mathbf{\Gamma}_{31}(\mathbf{\Gamma}_{31}^H \mathbf{\Gamma}_{31})^{-1} \mathbf{\Gamma}_{12} & \mathbf{I}_{N-2K} \\ -\mathbf{\Gamma}_{31}(\mathbf{\Gamma}_{31}^H \mathbf{\Gamma}_{31})^{-1} \mathbf{\Gamma}_{12} & \mathbf{I}_{N-2K} \end{bmatrix} \quad (60)$$

D'après l'équation 54 et 60 , on obtient l'estimation de la matrice \mathbf{V} :

$$\mathbf{V} = \begin{bmatrix} -\mathbf{\Gamma}_{21}^{-1} \mathbf{\Gamma}_{32}^H \mathbf{\Gamma}_{31}(\mathbf{\Gamma}_{31}^H \mathbf{\Gamma}_{31})^{-1} \mathbf{\Gamma}_{12} & -\mathbf{\Gamma}_{21}^{-1} \mathbf{\Gamma}_{32}^H \\ \mathbf{I}_K & \mathbf{0} \\ \mathbf{0} & \mathbf{I}_{N-2K} \end{bmatrix} \quad (61)$$

La méthode SWEDE définit aussi un pseudo-spectre à partir d'un projecteur $\mathbf{\Pi}_V$:

$$P(t) = \frac{1}{\mathbf{a}^H(t) \mathbf{\Pi}_V \mathbf{a}(t)} \quad (62)$$

avec :

$$\mathbf{\Pi}_V = \mathbf{V}(\mathbf{V}^H \mathbf{V})^{-1} \mathbf{V}^H \quad (63)$$

2.5.3 ESPRITWED (ESPRIT Without Eigen Decomposition)

La méthode SWEDE permet d'estimer les temps de retard par la position des maxima du pseudo-spectre. Cette étape nécessite une charge de calcul importante selon le pas d'échantillonnage temporel. De plus, on a vu dans la section 2.4.6, la méthode ESPRIT permet d'estimer directement les retards sans calculer le pseudo-spectre. En revanche, la méthode ESPRIT utilise la décomposition en éléments propres de la matrice de covariance. Cette étape est très lourde en temps de calcul. Pour éviter le calcul du pseudo-spectre et la décomposition en éléments propres, le principe de la méthode SWEDE a été combiné à celui de l'algorithme ESPRIT. Ce nouvel algorithme est baptisé ESPRITWED pour ESPRIT Without Eigen Décomposition.

La méthode ESPRITWED utilise une matrice \mathbf{G} qui présente l'image de l'espace signal [10] :

$$\mathbf{G} = \begin{bmatrix} \mathbf{\Gamma}_{12} \\ \mathbf{\Gamma}_{21}(\mathbf{\Gamma}_{13}\mathbf{\Gamma}_{31})^{-1}\mathbf{\Gamma}_{13}\mathbf{\Gamma}_{32} \\ \mathbf{\Gamma}_{32} \end{bmatrix} \quad (64)$$

Partitionnons la matrice \mathbf{G} de la manière suivante :

$$\mathbf{G} = \begin{bmatrix} \mathbf{G}_1 \\ - \end{bmatrix} = \begin{bmatrix} - \\ \mathbf{G}_2 \end{bmatrix} \quad (65)$$

Posons $\mathbf{G}_1 = \mathbf{G}_2\mathbf{H}$, alors après quelques développements mathématiques, nous remarquons que la matrice $\mathbf{\Phi}^{-1}$, l'équation 38, et la matrice \mathbf{H} sont similaires : Elles engendrent les mêmes valeurs propres. Donc, on peut estimer les retards à partir des valeurs propres de la matrice \mathbf{H} . La matrice \mathbf{H} peut être estimée au sens des moindres carrés :

$$\hat{\mathbf{H}} = (\mathbf{G}_2^H\mathbf{G}_2)^{-1}\mathbf{G}_2^H\mathbf{G}_1 \quad (66)$$

2.5.4 Résultats

De même façon, on a simulé deux chemins (2m et 6m) avec un SNR 10dB. Les figures 11 12 13 et 14 montrent respectivement les résultats pour ces méthodes haute résolution linéaire : OPM, Root-OPM, SWEDE et ESPRITWED. On peut déduire que ces méthodes haute résolution linéaire réduisent le temps de calcul par rapport aux méthodes haute résolution présentées dans la section 2.4.3 mais gardent leur résolution.

2.6 Méthode de parcimonie

D'après le modèle des observations fréquentielles, l'équation 1, le vecteur de mesure \mathbf{s} correspond à la transformée de Fourier du signal temporel $s(t)$. Du fait qu'on ne connaît les mesures fréquentielles que sur une bande B , la méthode de IFFT marche moins bien. En plus des méthodes HR pour résoudre ce problème, ils existent des méthodes dites de parcimonie.

2.6.1 Formalisation du problème LASSO

On connaît à priori que le signal temporel $s(t)$ est parcimonieux, dont chaque pic correspond à un trajet de propagation. On peut reformuler le problème en utilisant cette caractéristique de parcimonie. Notons $\mathbf{x} = (x_1, x_2, \dots, x_M)^T$, le vecteur temporel correspondant aux instants $(t_1, t_2, \dots, t_M)^T$ avec $M \gg N$, on peut estimer ce vecteur temporel en résolvant un problème d'optimisation :

$$\min \|\mathbf{x}\|_1 \quad s.t. \quad \|\mathbf{s} - \mathcal{F}\mathbf{x}\|_2^2 = 0 \quad (67)$$




FIGURE 11 – Résultat de la méthode haute résolution linéaire : OPM

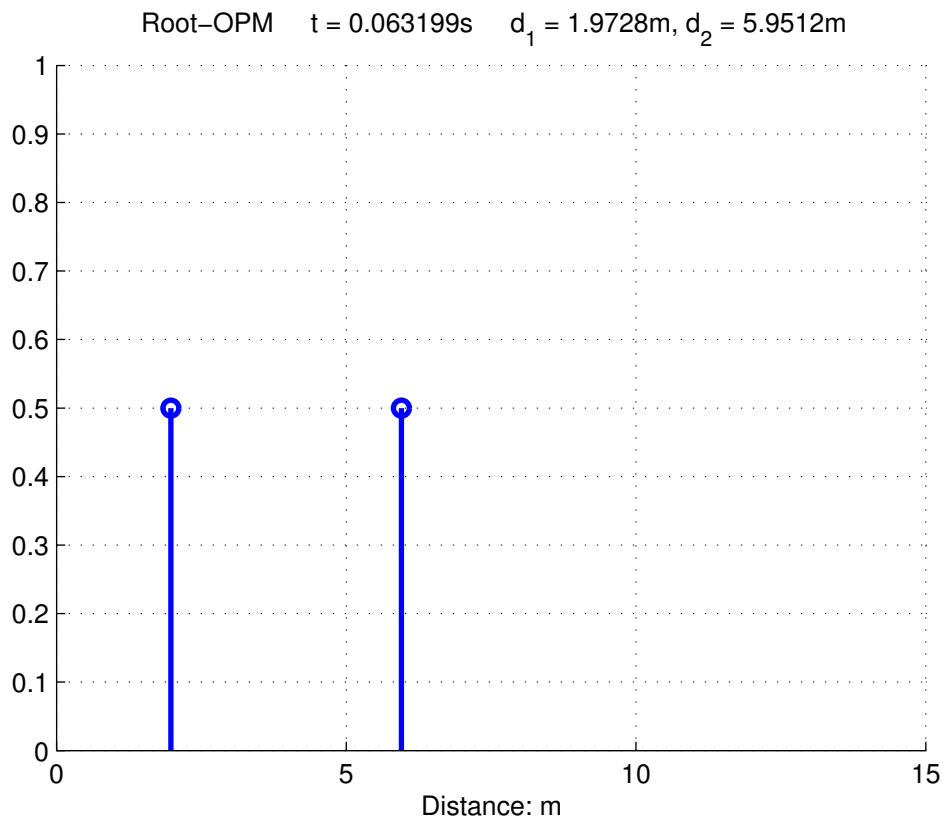


FIGURE 12 – Résultat de la méthode haute résolution linéaire : Root-OPM

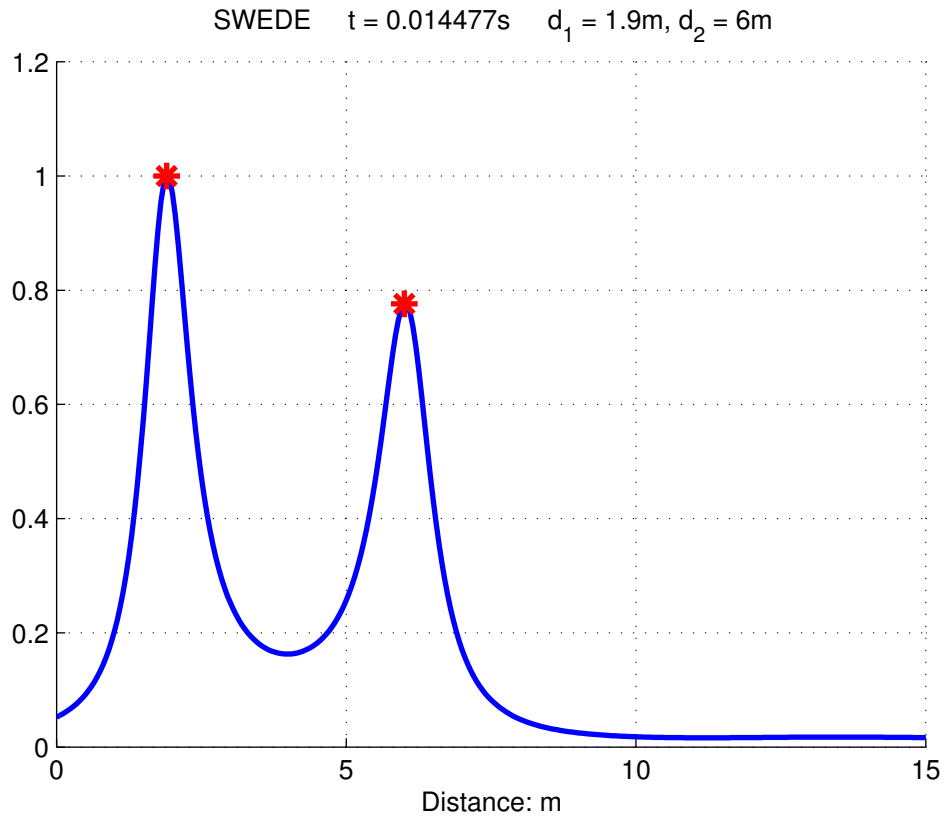


FIGURE 13 – Résultat de la méthode haute résolution linéaire : SWEDE

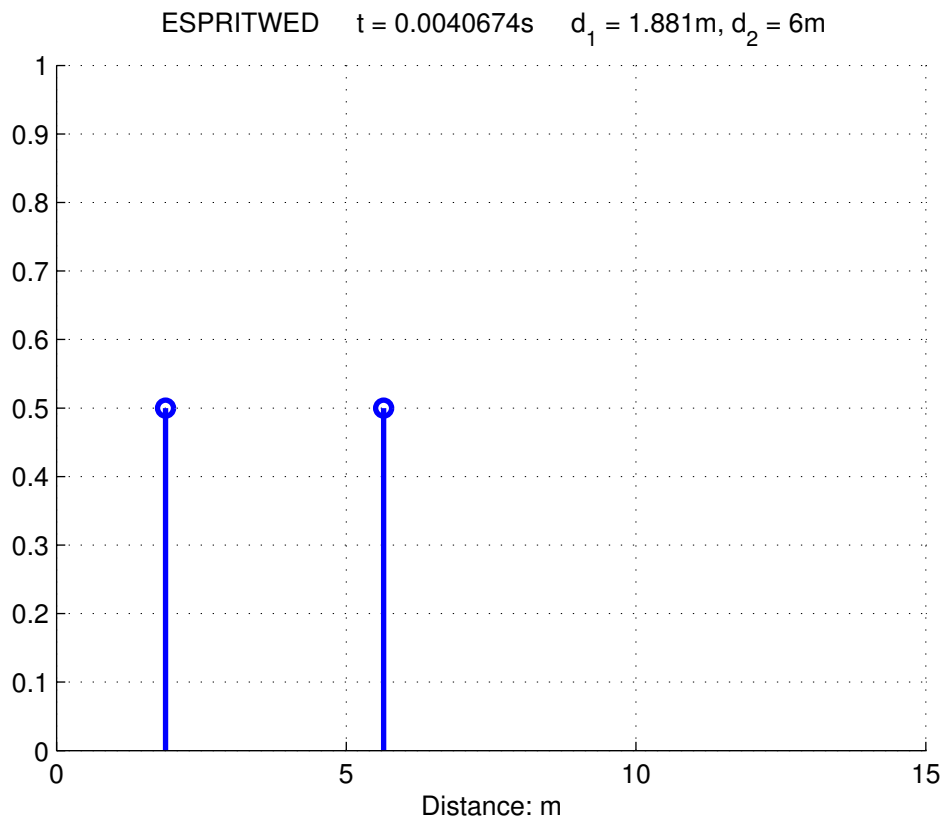


FIGURE 14 – Résultat de la méthode haute résolution linéaire : ESPRITWED

où \mathcal{F} est une matrice de transformée de Fourier de dimension (N, M) :

$$\mathcal{F}_{ij} = e^{-j2\pi f_i t_j} \quad i = 1, 2, \dots, N \quad j = 1, 2, \dots, M \quad (68)$$

Cette formulation, l'équation 67, peut être assimilée à un problème LASSO combinant un terme d'attache aux données et un terme de régularisation :

$$\mathbf{x} = \arg \min_{\mathbf{x}} \|\mathbf{s} - \mathcal{F}\mathbf{x}\|_2^2 + \lambda \|\mathbf{x}\|_1 \quad (69)$$

avec :

- $\|\mathbf{s} - \mathcal{F}\mathbf{x}\|_2^2$ est un terme d'attache aux données.
- $\lambda \|\mathbf{x}\|_1$ est un terme de régularisation.
- λ donne le compromis entre le terme d'attache aux données et le terme de régularisation. Plus il est grand, plus le résultat est parcimonieux.

2.6.2 FISTA (Fast Iterative Shrinkage Thresholding Algorithm)

ISTA est une famille des méthodes pour résoudre le problème inverse tel que ce problème LASSO. Cette famille des méthodes peut être vue comme une extension de la méthode de gradient. Grâce à sa simplicité, elle est efficace pour résoudre des problèmes volumineux. Par contre, elle peut être très lente en terme de convergence. [12] a proposé une nouvelle famille (FISTA) des méthodes qui garde la simplicité d'ISTA et en même temps, a une convergence plus rapide.

L'algorithme FISTA fait itérer le processus. Pour chaque itération, il utilise une variable intermédiaire \mathbf{u} . Pour l'itération $k + 1$:

- $\mathbf{u} = \mathbf{x}^k + \frac{k-1}{k+2}(\mathbf{x}^k - \mathbf{x}^{k-1})$
- $\mathbf{x}^{k+1} = \text{prox}_{t\lambda\|\cdot\|_1}(\mathbf{s} - t\mathcal{F}^T(\mathcal{F}\mathbf{u} - \mathbf{s}))$

avec :

- t le pas du processus : $t = \frac{1}{\|\mathcal{F}\|_2^2}$
 - $\text{prox}_{t\lambda\|\cdot\|_1}$ un opérateur proximal sur la fonction $t\lambda \|\cdot\|_1$:
- $$\text{si } \mathbf{y} = \text{prox}_{t\lambda\|\cdot\|_1}(\mathbf{x}), \text{ alors } y_i = \begin{cases} y_i \frac{|y_i| - t\lambda}{|y_i|} & x_i < t\lambda \\ 0 & \text{else} \end{cases}$$

2.6.3 Résultats

Avec la même simulation, la figure 15 montre le résultat de FISTA. On peut remarquer que cette méthode apporte moins d'erreur que la méthode IFFT et plus d'erreur que les méthodes haute résolution. De plus, cette méthode a un coût calculatoire très important par rapport aux méthodes précédentes.

En fait, on a remarqué que la résolution est inversement proportionnelle au largeur de bande. Pour le Bluetooth, on a une bande de 80MHz (2.4GHz). Si on a accès à d'autre bande, cela

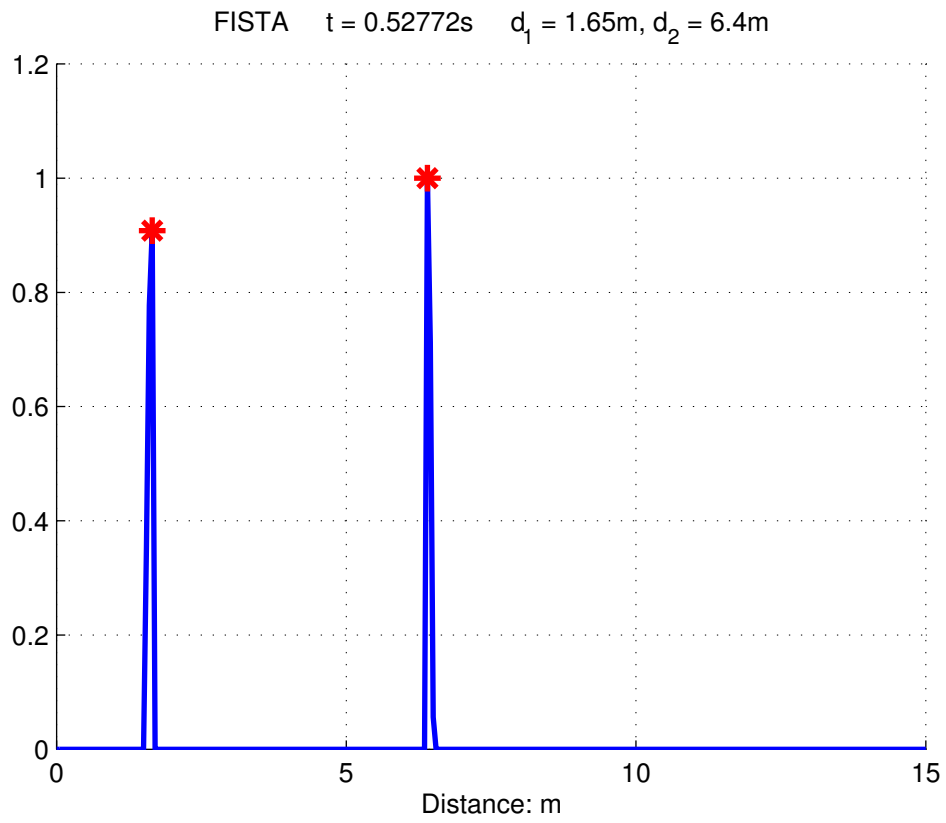


FIGURE 15 – Résultat de la méthode de parcimonie : FISTA




FIGURE 16 – Résultat de la méthode de parcimonie : FISTA pour la bande WIFI

nous permet d'augmenter proportionnellement la résolution en utilisant cette méthode FISTA. C'est le cas pour l'utilisation de WIFI. Ici, on utilise quatre bandes de WIFI (2.412-2.462GHz, 5.18-5.32GHz, 5.5-5.7GHz et 5.745-5.825GHz) [11] et on a simulé deux chemins très proche (2m et 3m). Du fait que la fréquence n'est plus équidistante, la méthode haute résolution ne peut plus marcher. Par contre, on peut utiliser FISTA et avoir une très bonne résolution. La figure 16 montre que la méthode FISTA peut distinguer deux chemins très proche tant qu'on dispose une largeur de bande plus grande. Plus la largeur de bande est grande, plus on a une meilleure résolution.

2.6.4 Amélioration du calcul

On a vu dans la section précédente que la méthode FISTA nous permet d'avoir une très bonne résolution tant qu'on a une largeur de bande plus grande. L'inconvénient de cette méthode est qu'elle demande un coût calculatoire très important (0.5s sur PC). Dans cette section, on va essayer d'améliorer le processus du calcul pour réduire le temps.

L'algorithme présenté ci-dessus calcule la distance en établissant une présentation redondante qui est essentiellement une grille contenant les distances potentielles. Si malheureusement la distance d'un chemin ne se trouve pas sur la grille, elle ne peut pas être localisée précisément. Une idée immédiate est de considérer une grille assez fine uniformément afin de trouver toutes les distances. Cependant, celle-ci augmente considérablement le coût de calcul. En fait, le temps de calcul dépend la taille de la matrice \mathcal{F} , d'où le pas d'échantillonnage du temps $(t_1, t_2, \dots, t_M)^T$. Dans ce cas, on utilise une approche adaptative dans le but d'atteindre une meilleure précision.

Le principe de cette approche est d'affiner la grille uniquement autour de régions où se situent les sources obtenues par une localisation préliminaire au lieu de mettre directement une grille fine uniformément. Cette approche nécessite de connaître approximativement les distances des sources, ceci peut être réalisé en utilisant en premier lieu une grille spacieuse. Ce processus peut être récurrent jusqu'à ce que la grille soit assez fine. Cet algorithme utilise seulement les amplitudes des solutions parcimonieuses. Les étapes principales de cet algorithme sont décrites dans la figure 17.

La figure 18 montre le résultat de simulation en utilisant une grille adaptative. On peut remarquer que le temps de calcul est réduit (0.25s au lieu de 0.55s).

2.7 Comparaisons de résolution

On a constaté que tous ces méthodes arrivent à estimer la distance pendant le cas où il y a seulement un chemin. Par contre, ces méthodes ont des performances très différentes en présence du multipath. Cette section est consacrée à comparer leurs performances de résolution en présence du multipath. On a choisi de comparer les performances des méthodes représentatives, telles que IFFT, ESPRIT, OPM et FISTA. Sous Matlab, on a simulé deux chemins avec le premier chemin fixe de 2m et le deuxième chemin varie de 7m à 2m. On montre l'erreur de détection du premier chemin en fonction de la distance du deuxième chemin.

2.7.1 Comparaison des résultats sans bruit

Dans un premier temps, on a comparé leurs performances de résolution pendant le cas où il n'y pas de bruit. La figure 19 montre que la méthode ESPRIT et OPM marchent très bien




FIGURE 17 – Approche adaptative




FIGURE 18 – Résultat de la méthode de parcimonie : FISTA avec une grille adaptative




FIGURE 19 – Comparaison des performances sans bruit

quand il n'y a pas de bruit. Par contre, la méthode FISTA présente un peu d'erreur quand le deuxième chemin s'éloigne du premier chemin et présente beaucoup d'erreur quand il s'approche. La méthode IFFT présente toujours beaucoup d'erreur, plus de 1m d'erreur.

2.7.2 Comparaison des résultats avec le bruit

Dans un deuxième temps, on a comparé leurs performances en ajoutant le bruit. La figure 20 montre que la méthode ESPRIT et OPM marchent toujours mieux que la méthode IFFT et FISTA. ESPRIT présente une meilleure précision quand le deuxième chemin est loin de 3m (1m de différence par rapport au premier chemin), mais présente des résultats très erronés quand il s'approche.

2.8 Bilan de comparaison

Dans cette partie, on essaye de donner un bilan de comparaison de tous les méthodes présentées ci-dessus en terme de la précision, la résolution, le coût calculatoire et l'extensibilité. On donne aussi les définitions des ces quatre termes :

Précision : Le pouvoir de bien estimer la distance avec moins d'erreur

Résolution : Le pouvoir de distinguer deux chemins proches

Coût calculatoire : Le temps nécessaire sur le PC pour obtenir le résultat

Extensibilité : La possibilité d'utiliser différentes bandes




FIGURE 20 – Comparaison des performances avec le bruit : $\text{SNR} = 10\text{dB}$

Tableau 1 montre les performances des ces méthodes. On peut constater que la méthode IFFT est la meilleure en terme de coût calculatoire mais avec une mauvaise précision et résolution. Les méthodes HR et HR linéaire gardent la meilleure précision et la résolution mais prennent un peu plus de temps par rapport à la méthode IFFT. Les méthodes d'extension telles que Root-MUSIC, Root-OPM, ESPRITWED permettent de réduire un peu de temps de calcul. La méthode FISTA gardent une performance moyenne en terme de précision et résolution. L'avantage de ce dernière est qu'elle peut marcher sur différentes bandes, cela permet finalement augmenter la précision et la résolution. L'inconvénient est le coût calculatoire, cela signifie qu'il faut un plate-forme plus performante pour qu'elle puisse marcher en temps réel.

TABLE 1 – Bilan de comparaison

Alogrithme	Précision	Résolution	Coût calculatoire	Extensibilité
IFFT	+	+	+++++	Non
MUSIC	+++	+++	++	Non
Root-MUSIC	+++	+++	+++	Non
Min-Norm	+++	+++	+++	Non
ESPRIT	+++	+++	+++++	Non
OPM	++	++	+++	Non
Root-OPM	++	++	+++++	Non
SWEDE	++	++	+++	Non
ESPRITWED	++	++	+++++	Non
FISTA	++	++	+	Oui

3 Prédiction de la zone

3.1 Introduction

3.1.1 RKE (Remote Keyless Entry)

Le système RKE nous permet de verrouiller ou déverrouiller facilement la porte de la voiture en appuyant sur des boutons. Ce système utilise un key fob qui transmet la commande de verrouillage ou déverrouillage quand le propriétaire appuie sur le bouton. La voiture est équipée d'un système ECU (Electronic Control Unit) qui reçoit et authentique le signal de commande et puis contrôle la porte.

3.1.2 PEPS (Passive Entry Passive Start)

PEPS est un nouveau système main libre qui nous permet de verrouiller et déverrouiller la porte ou le coffre sans toucher le key fob à seule condition que le key fob soit présenté avec le propriétaire (dans le sac ou la poche).

Le fonctionnement du PEPS est basé principalement sur la localisation du key fob. Il utilise LF (Low Frequency) pour la communication entre le key fob et la voiture. La voiture est équipée de quatre ou six antennes à l'intérieur ou en périphérie. Le key fob mesure le RSSI (Received Signal Strength Indication) de chaque antenne et puis analyse et détermine la position (l'intérieur, l'extérieur et proche ou l'extérieur et loin) du key fob. Une fois la position est déterminée, la voiture (ECU) peut réagir selon la commande donnée par le key fob.

3.1.3 PEPS avec le smartphone

Le PEPS décrit précédemment demande un équipement spécifique, le key fob. Une alternative est de réaliser tous les fonctionnements d'un PEPS en utilisant un équipement déjà possédé par chacun, par exemple, le smartphone ou le montre. Dans cette section, on va chercher les méthodes pour localiser un smartphone avec le Bluetooth.

3.2 Méthode

3.2.1 Architecture du système

Quatre beacons sont mises en place sur la voiture : un à l'intérieur et trois sur la périphérie. La figure 21 montre les positions de ces beacons. Beacons sont des petits capteurs sans fil à basse consommation d'énergie et facilement dissimulables. Ces petits appareils très abordables, qui fonctionnent comme des capteurs qui utilisent la connexion Bluetooth et des batteries à faible énergie, peuvent s'accrocher à un mur ou un comptoir et transmettre des messages directement à un smartphone ou une tablette. Le smartphone reçoit le RSSI (Received Signal Strength Indication) de chaque beacon par le Bluetooth. Le but est de localiser le smartphone en analysant ces RSSIs.

3.2.2 Cahier des charges : PEPS zones

Le système PEPS doit être capable à verrouiller ou déverrouiller la porte et démarrer la voiture sans le toucher. Cela signifie que le PEPS doit connaître dans quelle zone se trouve le smartphone. On définit cinq zones pour la position du smartphone (Start, Unlock Left, Unlock Right,




FIGURE 21 – Position des beacons sur la voiture




FIGURE 22 – Cahier des charges : PEPS zones

Unlock Back et Lock). La figure 22 présente les définitions de ces zones :

Start : Le smartphone est à l'intérieur de la voiture. Cela permet de démarrer la voiture.

Unlock Left : Le smartphone est à la distance de deux mètres maximale de la porte gauche. Cela permet de déverrouiller la voiture et d'ouvrir la porte de conducteur.

Unlock Right : Le smartphone est à la distance de deux mètres maximale de la porte droite. Cela permet de déverrouiller la voiture et d'ouvrir la porte de passager.

Unlock Back : Le smartphone est à la distance de deux mètres maximale de la porte arrière. Cela permet de déverrouiller la voiture et d'ouvrir la porte de coffre.

Lock : Le smartphone n'est pas dans les zones définies précédentes. Il est au moins deux mètres loin de la voiture. Cela permet de verrouiller la voiture.

3.2.3 RSSI (Received Signal Strength Indication) et atténuation

En télécommunications, le Received Signal Strength Indication ou RSSI est une mesure de la puissance en réception d'un signal reçu d'une antenne (classiquement un signal radio). Son utilité est de fournir une indication sur l'intensité du signal reçu. Ainsi, le signal peut être mesuré en analogique ou en continu, par exemple à partir d'une échelle 0/5 V (le niveau le plus élevé est 5 V, le plus bas est 0 V) ou, le plus souvent, à partir d'une échelle de puissance généralement référencée en mW.

La signification de la mesure, exprimée dans une échelle logarithmique (souvent en dBm) est la suivante :

$$RSSI = 10 \log\left(\frac{P}{1mW}\right) \quad (70)$$

Cela signifie que une valeur de 0 dBm correspond à une puissance reçue de 1 mW et une valeur de -30 dBm correspond à une puissance reçue de 1 microwatt.

Dans le cas de la propagation en espace libre et si les deux antennes ont même polarisation, il est possible de connaître le niveau de puissance reçu par une antenne de réception, en fonction de la distance à l'antenne d'émission et de la puissance de l'émetteur. Si l'antenne d'émission et l'antenne de réception sont isotropes (gain 0dB), l'atténuation entre les deux antennes est la suivante :

$$A = 22 + 20 \log\left(\frac{D}{\lambda}\right) \quad (71)$$

où A est l'atténuation en dB, D est la distance entre deux antennes et λ est la longueur d'onde. La figure 23 montre un exemple d'atténuation théorique. On peut constater que le RSSI diminue rapidement quand le smartphone est proche de la voiture et diminue doucement quand il est loin.

Dans la réalité, il y a plusieurs facteurs qui peuvent rendre le RSSI reçu variable. Ci-dessous est une liste des facteurs plus importants :

- Propagation dans le canal réel
- Atténuation par le corps ou le sac
- Polarisation d'antenne dans le smartphone




FIGURE 23 – Atténuation théorique du signal reçu par le smartphone

En fait, l'atténuation du signal reçu dépend non seulement la distance entre deux antennes. Elle dépend aussi le multipath et la géométrie de la voiture. La longueur d'onde Bluetooth est 12.5cm, cela signifie que tous les obstacles de taille de plus de 12.5cm peuvent réduire la puissance du signal. La figure 24 montre un exemple d'atténuation dans un canal réel. On peut constater que le RSSI n'est plus descendant selon la distance à cause du multipath ou la géométrie de la voiture. La figure 25 montre l'influence du corps sur la puissance du signal reçu. On peut voir 3dB de différence à cause du corps.

La puissance reçue par le smartphone dépend aussi l'orientation du smartphone posé. Du fait que la polarisation d'antennes dans le smartphone n'est pas isotrope, il y a une grande différence de puissance reçue dans différentes orientations. La figure 26 montre que les gains d'antennes sont différents pour différentes orientations du smartphone.

3.2.4 Choix des attributs

Afin d'utiliser la méthode de Machine Learning avec une meilleure précision, il faut bien choisir les attributs pertinents. On dispose des RSSIs pour chaque beacon et un capteur de lumière qui nous permet de savoir si le smartphone est dans la poche ou non. On a vu dans la section précédente que le RSSI reçu varie énormément quand il y a un obstacle (corps, mains, etc) au milieu. Mais, ces obstacles apportent moins d'influence sur la différence entre deux beacons. Donc, on a choisi les différences des RSSIs entre les beacons périphériques et le beacon central. En plus, on utilise la moyenne des RSSIs de quatre beacons qui nous donne une "distance" globale du smartphone. Ci-dessous est une liste de tous les attributs qu'on utilise pour les méthodes de Machine Learning :

- L** : RSSI reçu du beacon gauche
- R** : RSSI reçu du beacon droite
- M** : RSSI reçu du beacon central

Real propagation channel




FIGURE 24 – Atténuation de propagation dans le canal réel




FIGURE 25 – Atténuation par le corps


Azimuth 0°	Elevation	Polar H	Polar V
	0°	2.5	-13
	45°	1	-10
	90°	-4	-9

FIGURE 26 – Influence de la polarisation du smartphone

B : RSSI reçu du beacon arrière

LM : Différence du RSSI entre le beacon gauche et le beacon central

RM : Différence du RSSI entre le beacon droite et le beacon central

BM : Différence du RSSI entre le beacon arrière et le beacon central

Mean : La moyenne des RSSIs de ces quatre beacons

P : Variable booléen, $P = 1$ si le smartphone est dans la poche

3.2.5 Random Forest

Random Forest (ou les forêts d'arbres décisionnels en français) ont été formellement proposées en 2001 par Leo Breiman et Adèle Cutler. Elles font partie des techniques d'apprentissage automatique. Cet algorithme combine les concepts de sous-espaces aléatoires et de bagging. L'algorithme des forêts d'arbres décisionnels effectue un apprentissage sur de multiples arbres de décision entraînés sur des sous-ensembles de données légèrement différents.

La base du calcul repose sur l'apprentissage par arbre de décision. La proposition de Breiman vise à corriger plusieurs inconvénients connus de la méthode initiale, comme la sensibilité des arbres uniques à l'ordre des prédicteurs, en calculant un ensemble de B arbres partiellement indépendants. Une présentation rapide de la proposition peut s'exprimer comme suit :

1. Créer B nouveaux ensembles d'apprentissage par un double processus d'échantillonnage :
 - Sur les observations, en utilisant un tirage avec remise d'un nombre N d'observations identique à celui des données d'origine (technique connue sous le nom de bootstrap)
 - sur les p prédicteurs, en n'en retenant qu'un échantillon de cardinal $m < \sqrt{p}$
2. Sur chaque échantillon, on entraîne un arbre de décision selon une des techniques connues, en limitant sa croissance par validation croisée.
3. On stocke les B prédictions de la variable d'intérêt pour chaque observation d'origine.
4. La prédiction de la forêt aléatoire est alors un simple vote majoritaire (Ensemble learning).

3.3 Résultat

Dans un premier temps, on a collectionné une base de données de 24166 observations pour ces 5 zones (start, unlock left, unlock right, unlock back et lock). On utilise trois quarts (18126 observations) pour entraîner un modèle de Random Forest et le reste un quart (6040 observations)

Confusion Matrix and Statistics

Prediction	Reference				
	lock	start	unlock_back	unlock_left	unlock_right
lock	1103	12	59	73	67
start	8	1930	2	23	24
unlock_back	61	1	736	6	17
unlock_left	53	30	11	940	9
unlock_right	65	26	11	7	766

Overall Statistics

Accuracy : 0.9065
95% CI : (0.8988, 0.9137)
No Information Rate : 0.331
P-Value [Acc > NIR] : <2e-16

Kappa : 0.8793
McNemar's Test P-Value : 0.5915

FIGURE 27 – Matrice de confusion sur le modèle de Random Forest

pour valider ce modèle. Le paramètre de Random Forest m est choisi en utilisant la méthode 10-fold validation croisée et on obtient la meilleure valeur pour $m = 2$. Une fois le modèle est construit, on le valide sur le reste ensemble. La figure 27 montre le résultat de la matrice de confusion. On peut constater qu'on a une précision de 91%.

4 Conclusion

Pendant ce stage, j'exploitais principalement deux sujets sur la localisation du smartphone. Le premier est focalisé sur le calcul de distance entre le smartphone et la voiture. Le deuxième consiste à estimer la zone où se trouve le smartphone. Ce deuxième donne une localisation approximative du smartphone au lieu de chercher une position précise qui est fournie par le premier, le calcul de distance.

Dans la première partie, je distinguais cinq familles des méthodes : méthode de phase, méthode conventionnelle (IFFT), méthode de haute résolution, méthode de haute résolution linéaire et méthode de parcimonie (FISTA). Toutes ces méthodes peuvent calculer la distance quand il y a seulement un chemin. La méthode de phase est une méthode plus simple, mais elle ne peut plus marcher quand il y a du multipath (Par exemple, deux chemins pendant la propagation du signal). La méthode IFFT est la première méthode directe qui peut résoudre le multipath. Mais, elle n'est pas performante en terme de précision (environ 1m d'erreur) et résolution (3.75m pour une bande de 80MHz). Cela n'est pas satisfaisant pour notre application. Donc, on a abordé des méthodes dites haute résolution telles que MUSIC et ESPRIT qui sont caractérisées par leur meilleure résolution et précision. L'inconvénient de ces méthodes est qu'elles demandent une décomposition en éléments propres de la matrice de covariance. Cela nécessite une grande partie du temps de calcul. C'est la raison pour laquelle qu'on présente leurs extensions dites haute résolution linéaire telles que OPM, SWEDE et ESPRITWED. Ces méthodes dernières ne demandent pas de décomposition de la matrice de covariance mais gardent la résolution et la précision des méthodes HR (haute résolution). Ensuite, on a proposé une autre famille de méthode (FISTA). On le considère comme une optimisation en formant un problème de LASSO. La méthode FISTA a une résolution et précision moyenne. L'avantage de cette nouvelle méthode est sa extensibilité. C'est-à-dire, elle peut utiliser les fréquences dans différentes bandes (Par exemple, pour le WIFI). Du fait que la résolution est inversement proportionnelle à la largeur de bande, on peut augmenter la résolution en utilisant plusieurs bandes avec FISTA.

Dans la deuxième partie, j'utilisais la méthode de Machine Learning (Random Forest) pour estimer la zone où se trouve le smartphone. On définit cinq zones (start, unlock left, unlock right, unlock back et lock) pour la position du smartphone. On a mis 4 beacons sur la voiture. Pour l'instant on utilise ces quatre RSSIs reçus par le smartphone et un variable booléen P qui signifie si le smartphone est dans la poche pour entraîner un modèle de Random Forest. Ce modèle est validé sur une autre base des données avec une précision d'environ 90%.

Le calcul de distance nécessite de construire le vecteur d'observation qui demande un équipement spécifique à partir du smartphone. Néanmoins, l'estimation de la zone peut être effectuée directement sur le smartphone. Il reste encore des pistes pour améliorer la précision. On a vu que le RSSI dépend aussi l'orientation du smartphone. Donc, il vaut mieux d'intégrer les informations d'orientation dans le modèle de Machine Learning. Une autre piste est d'ajouter des beacons sur la voiture pour avoir plus d'information des RSSIs.

Références

- [1] Xin li, Yimin Zhang and Moeness G. Amin. *Multifrequency-Based Range Estimation*. IEEE International Conference On RFID, 2009.
- [2] Daniel Goncalves et Patrick Gounon . *Décorrélation de sources large bande en traitement d'antenne actif à haute résolution*. Seizième colloque GRETSI, 15-19 Septembre 1997.
- [3] Cédric Le Bastard. *Apport de techniques de traitement du signal super et haute résolution à l'amélioration des performances du radar-chaussée*. Signal and Image Processing. Université de Nantes, 2007.
- [4] Hua Ma. *Localisation de sources par méthodes à haute résolution et par analyse parcimonieuse*. Université de Franche-Comté, 2011.
- [5] H.Akaike. *A new look at the statistical model identification*. IEEE Trans, Automatic Control, vol.AC-19, no.6, pp.716-723.
- [6] J.Rissanen. *Modeling by shortest data description*. Automatica, vol.14, no.5, pp.465-471, 1985.
- [7] Emanuel Radoi, André Quinquis. *A New Method for Estimating the Number of Harmonic Components in Noise with Application in High Resolution Radar*. EURASIP Journal on Applied Signal Processing 2004 :8, 1177-1188.
- [8] S.L.Jr.Marple. *Digital Spectral Analysis with Applications*. Signal Processing Series, Series Editor, 1987.
- [9] S.M.Kay, S.L.Jr, Marple. *Spectral Traitement Analysis - A Modern Perspective*. Processing of IEEE, Vol. 69, No. 11, November 1981.
- [10] A.Eriksson, P.Stoica and T.Söderström. *On line Subspace Algorithms for Tracing Moving Source*. IEEE Trans, Signal Processing, Vol. 42, No. 5, pp 2319-2330, September 1994.
- [11] Deepak Vasisht, Swarun Kumar, Dina Katabi. *Decimeter-Level Localisation with a Single WiFi Access Point*. Proceedings of the 13th USENIX Symposium on Networked Systems Design and Implementation(NSDI'16).
- [12] Amir Beck, Marc Teboulle. *A Fast Iterative Shrinkage Thresholding Algorithm for Linear Inverse Problems*. SIAM J.Imaging Sci. 2(1), 183-202.
- [13] Hichem Semira, Hocine Belkacemi, Sylvie Marcos. *High-Resolution Source Localization Algorithm Based on the Conjugate Gradient*. EURASIP Journal on Advances in Signal Processing, Volume 2007, Article ID 73871, 9 pages.